```
11/13/24, 7:00 PM
                                                                                                                                                                                     Proyecto 1.ipynb - Colab
         #PROYECTO 01
         #Integrante- Aranza Moreira Sanchez
         import pandas as pd import
          seaborn as sns import
         matplotlib.pyplot as plt
         # Dataset url =
          'https://raw.githubusercontent.com/samuelsaldanav/datasets/main/Bank%20Customer%20Churn%20Prediction/Churn_Modelling.csv'
         data = pd.read_csv(url)
         display(data.head())
         # Eliminar valores nulos
         data cleaned = data.dropna()
         # Duplicados duplicates =
          data_cleaned.duplicated().sum() if
          duplicates > 0:
                   print(f'Existen {duplicates} duplicados en el dataset')
                                 print('No hay duplicados en el dataset')
         # variables categóricas data_encoded = pd.get_dummies(data_cleaned, columns=['Geography',
          'Gender'], drop_first=True)
         # Ver las columnas generadas por pd.get_dummies
         print(data_encoded.columns)
         # outliers en variables numéricas numeric_columns = ['CreditScore', 'Age', 'Tenure', 'Balance',
          'NumOfProducts', 'EstimatedSalary'] plt.figure(figsize=(15, 10)) for i, column in
          enumerate(numeric_columns, 1):
                   plt.subplot(3, 3, i)
          sns.boxplot(y=data_encoded[column])
         plt.title(f'Boxplot de {column}')
          plt.xlabel(column) plt.tight_layout()
         plt.show()
         # conversion
         Q1 = data_encoded['CreditScore'].quantile(0.25)
         Q3 = data_encoded['CreditScore'].quantile(0.75) IQR = Q3 - Q1 lower_bound = Q1 - 1.5 * IQR upper_bound = Q3 + 1.5 * IQR upper_bound = Q4 + 1.5 * IQR upper_bound = Q5 + 1.5 * IQR upper_bound = Q6 + 1.5 * IQR upper_bound
         data_cleaned = data_encoded[(data_encoded['CreditScore'] >= lower_bound) & (data_encoded['CreditScore'] <= upper_bound)]</pre>
         print(f"Tamaño original: {data_encoded.shape[0]}")
         print(f"Tamaño sin outliers: {data_cleaned.shape[0]}")
         plt.figure(figsize=(10, 6))
         sns.boxplot(x=data_cleaned['CreditScore'])
         plt.title('Boxplot de CreditScore sin Outliers')
         plt.show()
         Q1 = data_cleaned['Age'].quantile(0.25)
         Q3 = data_cleaned['Age'].quantile(0.75) IQR = Q3 - Q1 lower_bound = Q1 - 1.2 * IQR upper_bound = Q3 +
         1.2 * IQR data_cleaned = data_cleaned[(data_cleaned['Age'] >= lower_bound) & (data_cleaned['Age'] <=</pre>
         upper_bound)] print(f"Tamaño sin outliers para Age: {data_cleaned.shape[0]}")
         plt.figure(figsize=(10, 6))
         sns.boxplot(x=data_cleaned['Age'])
         plt.title('Boxplot de Edad sin Outliers')
         plt.show()
         Q1 = data_cleaned['NumOfProducts'].quantile(0.25)
         Q3 = data_cleaned['NumOfProducts'].quantile(0.75) IQR = Q3 - Q1 lower_bound = Q1 - 1.5 * IQR upper_bound = Q3 + 1.5 * IQR upper_bound = Q4 + 1.5 * IQR upper_bound = Q5 + 1.5 * IQR upper_bou
         data_cleaned = data_cleaned[(data_cleaned['NumOfProducts'] >= lower_bound) & (data_cleaned['NumOfProducts'] <= upper_bound)]</pre>
         print(f"Tamaño sin outliers para NumOfProducts: {data_cleaned.shape[0]}")
         plt.figure(figsize=(10, 6))
         sns.boxplot(x=data_cleaned['NumOfProducts'])
         plt.title('Boxplot de NumOfProducts sin Outliers')
         plt.show()
         # Estadísticas descriptivas
         statistics = data_cleaned.describe()
         print("Estadísticas Descriptivas:\n")
         display(statistics)
```

```
# histogramas plt.figure(figsize=(15,
12)) for i, col in
enumerate(numeric_columns):
   plt.subplot(3, 2, i + 1)
sns.histplot(data_cleaned[col], bins=20, kde=True)
plt.title(f'Distribución de {col}')
plt.xlabel(col) plt.ylabel('Frecuencia')
plt.tight_layout() plt.show()
# Visualización gráficos de barras plt.figure(figsize=(12, 6)) geo_columns
= [col for col in data_cleaned.columns if 'Geography_' in col]
# Gráficos de columna de Geografía for i,
geo_col in enumerate(geo_columns, 1):
                                           sns.countplot(x=geo_col, data=data_cleaned) # Usar 'data_cleaned' porque es
   plt.subplot(1, len(geo_columns), i)
el DataFrame después de pd.get_dummies()
                                          plt.title(f'Frecuencia de Clientes por {geo_col}')
                                                                                                  plt.xlabel(geo_col)
plt.ylabel('Frecuencia')
plt.tight_layout()
plt.show()
# Gráfico de dispersión plt.figure(figsize=(10, 6))
sns.scatterplot(x='Age', y='Balance', hue='Exited', data=data_cleaned)
plt.title('Relación entre Edad y Balance') plt.xlabel('Edad')
plt.ylabel('Balance') plt.show()
# dataset limpio
data_cleaned.to_csv('/content/cleaned_dataset.csv', index=False)
```

